

RAG(検索拡張生成)解説資料

Retrieval-Augmented Generation

1. RAGとは

RAG(Retrieval-Augmented Generation: 検索拡張生成)は、生成AI(LLM)が外部の情報源を検索して取り込み、それを参照しながら回答を生成する仕組みです。

従来のAIはモデル内部の知識に依存するため、「学習後に増えた情報」や「ローカルの資料」を扱うことが苦手でした。

RAGはこの問題を、検索(Retrieval)と生成(Generation)を組み合わせることで解決します。

RAGは以下の3単語から成り立っています。

- **Retrieval**(検索)
→ 保存されたデータから、質問に関連する情報を取り出す
 - **Augmented**(拡張)
→ 検索結果をAIへ追加し、回答生成能力を拡張する
 - **Generation**(生成)
→ 追加された情報を参考に、新しい文章・回答を生成する
-

2. RAGが必要とされる理由

① 知識の更新ができない問題

LLMは学習した時点の情報に固定されているため、

- ・最新ニュース
- ・手元のPDF
- ・企業内文書

といった“新しい情報”には対応できません。

② ハルシネーション(事実誤認)が発生

根拠となるデータにアクセスできないと、AIは“推測でそれっぽい回答”を作ってしまう。

③ 情報の根拠が不透明

LLMは「どの情報を元にした回答か」を示すことが苦手。

3. 仕組みの全体像

RAGは大きく分けて **3つのステップ** で動作します。

1. 知識ベースの準備
文書を分割し、ベクトル化してデータベースに保存
 2. 質問に関連する情報を検索
質問をベクトル化して検索し、「意味的に近い文書」を取得
 3. 生成AIが回答を作成
取得した文書を参照しながら、正確な文章を生成
-

4. 各ステップの詳細

STEP 1: 知識ベースを準備する

外部データ(PDF、テキスト、Webページなど)をAIが扱いやすい形に変換する。

- 文書を小さな単位(チャンク)に分割
- Embedding(埋め込みモデル)でベクトル化
- ベクトルデータベースへ保存

こうして、AIが後で検索できる「意味ベースの辞書」が構築されます。

STEP 2: 質問に関連する情報を検索する

ユーザーの質問も同じくベクトル化し、
「意味的に近い」文書を探し出す。

特徴:

- キーワード一致ではなく“文意”で検索できる
 - 表現が違っていても意味が近ければヒットする
 - 大量データから必要な断片だけを正確に抽出できる
-

STEP 3: 回答を生成する

検索で得た文書をLLMに渡し、
「次の情報を参考にして回答を作成してください」と指示する。

これにより、

- 根拠のある回答
- 最新情報を反映した回答
- ハルシネーションの抑制

が実現される。

5. RAGの技術的ポイント

- ベクトル検索の強み

AIは文章を「数値(ベクトル)」として理解するため、似た意味の文章を柔軟に検索できる。

例:

- 「請求書」⇔「支払明細」
- 「事故」⇔「衝突」

単純なキーワード検索より圧倒的に高精度。

- チャンク分割(Chunking)の重要性

RAGの精度は 文書の分割方法 に大きく左右される。

- チャンクが大きすぎる → ノイズが増える
- 小さすぎる → 文脈が切れてしまう

一般的には **200～1000文字** が推奨される。

- 再ランク(Rerank)

検索結果をさらにAIで評価し、
本当に関連する文章だけを取り出すことで精度が上がる。

6. RAGのメリット

- 最新の情報を参照できる
→ 文書を追加するだけでAIが扱える情報が増える
 - 正確性が向上する
→ 実際の資料を参照するため、事実に基づく回答が可能
 - 透明性が高い
→ どの文書を参照したか提示できる
 - 再学習が不要で低コスト
→ モデルを更新しなくても情報を後付けできる
-

7. RAGの課題・注意点

- 検索が間違えると回答も間違う (Garbage In → Garbage Out)
 - チャンク設計に依存する
 - 文章を長く渡しすぎるとノイズになる
 - ベクトルDBやEmbeddingの品質も重要
-

8. まとめ

RAGは、

- 検索の正確さ
- 生成AIの柔軟さ

を組み合わせた、現在最も注目されるAI活用手法です。

従来の生成AIが抱えていた

「情報が古い」「根拠が不透明」「事実の誤り」

といった課題を解決し、最新・正確・根拠のある回答を実現します。

企業内データやローカルファイルとの連携、専門ドメインの検索システム、FAQボットなど、さまざまな用途で利用されています。